

Парсинг - получение контента с web-страниц на PHP

Запросы к web-страницам

- CURL

Выбор текстовых данных из структуры HTML-документа

- Simple HTML DOM Parser,
- PHPQuery

1. Библиотека CURL (client urls)

библиотека функций, позволяет взаимодействовать с множеством различных серверов по многим различным протоколам.

```
<?php
```

```
$ch = curl_init();
```

```
curl_setopt($ch, CURLOPT_URL, "http://localhost/index1.php");
```

```
$fp=fopen("example_homepage.txt","w");
```

```
curl_setopt($ch,CURLOPT_RETURNTRANSFER,1);
```

```
curl_setopt($ch, CURLOPT_FILE,$fp);
```

```
curl_setopt($ch, CURLOPT_HEADER, 0);
```

```
curl_exec($ch);
```

```
curl_close($ch);
```

```
fclose($fp);
```

```
?>
```

```
curl_multi_init();
```

```
curl_multi_exec($mh, $run)
```

```
curl_multi_info_read($mh);
```

```
curl_multi_getcontent($ch)
```

```
curl_getinfo($ch,CURLINFO_EFFECTIVE_URL)
```

Многопоточные запросы

<?php

```
$aURLs = array("http://www.php.net", "http://www.w3cschools.com");
```

```
$mh = curl_multi_init();
```

```
$aCurlHandles = array();
```

```
foreach ($aURLs as $id=>$url) {
```

```
    $ch = curl_init();
```

```
    curl_setopt($ch, CURLOPT_URL, $url);
```

```
    curl_setopt($ch, CURLOPT_RETURNTRANSFER, 1);
```

```
    curl_setopt($ch, CURLOPT_HEADER, 0);
```

```
    $aCurlHandles[$url] = $ch;
```

```
    curl_multi_add_handle($mh, $ch); }
```

```
$active = null;
```

```
do { $mrc = curl_multi_exec($mh, $active); }
```

```
while ($mrc == CURLM_CALL_MULTI_PERFORM);
```

```
while ($active && $mrc == CURLM_OK) {
```

```
    if (curl_multi_select($mh) != -1) {
```

```
        do { $mrc = curl_multi_exec($mh, $active); }
```

```
        while ($mrc == CURLM_CALL_MULTI_PERFORM);    }}
```

```
foreach ($aCurlHandles as $url=>$ch) {
```

```
    $html = curl_multi_getcontent($ch);
```

```
    ...
```

```
    curl_multi_remove_handle($mh, $ch); }
```

```
curl_multi_close($mh);
```

?>

2. Simple HTML DOM Parser

Пример: отзывы о банках

Тюмень

ВходПоиск

banki.ru

БАНКИСТРАХОВАНИЕИНВЕСТИЦИИСВЯЗЬ И ИНТЕРНЕТ

КРЕДИТЛОТО

ПРОДУКТЫ И УСЛУГИБАНКИ И КОМПАНИИНОВОСТИРЕЙТИНГИОБЩЕНИЕСЕРВИСЫБАНК ГОДА

Самовольное подключение платных услуг

оценка: 1

Получил СМС "Вам подключена услуга такая-то, 90 дней бесплатно. Чтобы отказаться от подключения, отправьте в течении суток ответное СМС с цифрой 1".

Вот и отправляю в ответ цифру 1. Только не по СМС, а сюда.

Нагуглил несколько похожих отзывов. Такими рассылками с номера 2273 ТКС баловались и в 2015, и в 2017 году. Представители банка в ответ делают невинные глаза: "удобная же услуга, что вам не нравится?" (потому и не указываю, что... Читать далее

23.02.2019 18:29

✓ Ответ банка

Не верь рекламе - там обман

оценка: 1

Очень срочно понадобились деньги и решили обратиться в тинькофф банк, т. К по рекламе обещают деньги на следующий день под залог недвижимости.. Чушь полная, уже пошла вторая неделя после подписания документов, денег так и нет..... Позавчера звонили в банк, сказали ждите представителя, поставите ещё одну подпись и все деньги сразу придут..... А нет, подпись поставили, представитель уехал, позвонили с банка и сказали ждите ещё в течении двух... Читать далее

23.02.2019 12:08

✓ Ответ банка

Честность сотрудников

Народный рейтинг	1 место высшая лига
Клиентов на Банки.ру	11793
Отзывы	27340

ОТЗЫВЫ О ПРОДУКТАХ БАНКА

Потребительские кредиты

Автокредиты

Вклады

Дебетовые карты

Дистанционное обслуживание

Ипотечные кредиты

Кредитные карты

Кредитование бизнеса

Лизинг

Код страницы

```
<article class="responses__item" data-state="collapsed" data-id="10222008" data-test="responses-item">
  <div>
    <a class="header-h3" data-test="responses-header" href="/services/responses/bank/response/10222008/">
      Обман в информации о доходе по вкладу в ИБ
    </a>
  </div>

  <div class="responses__item_message" data-preview data-test="responses-message">
    Банк стал слишком безответственным за свои косяки в сервисах дистанционного обслуживания. Для дистанционного банка это недопустимо.<br><br>В интернет банке в информации на вкладки "События" по действующему вкладу в полях "Прогноз дохода" и "Прогноз баланса" завышены цифры для моего вклада на 6 мес. Там отображаются прогнозы, которые сошлись бы, если бы вклад был открыт на 7 мес.<br><br>На вкладке прогноз дохода такая же ошибка. Там же на графике...
    <span data-click="expand" class="pseudo-link">Читать далее</span>
  </div>
  <div class="responses__item_message markup-inside-small markup-inside-small--bullet" data-full>
    Банк стал слишком безответственным за свои косяки в сервисах дистанционного обслуживания. Для дистанционного банка это недопустимо.<br><br>В интернет банке в информации на вкладки "События" по действующему вкладу в полях "Прогноз дохода" и "Прогноз баланса" завышены цифры для моего вклада на 6 мес. Там отображаются прогнозы, которые сошлись бы, если бы вклад был открыт на 7 мес.<br><br>На вкладке прогноз дохода такая же ошибка. Там же на графике при наведении на "Дек" во всплывающем окне "Баланс на 23 декабря" не соответствует реальному балансу вклада.<br><br>Вклад очень простой, открыт в одной валюте, никаких пополнений. Вероятно банк экономит при найме профессионалов для разработки своих сервисов.<br><br>Оценку сниму только, если банк на дату окончания вклада выплатит именно ту сумму, которая отображается в ИБ.
  </div>
  <footer class="clearfix">
    <time class="display-inline-block" data-test="responses-datetime">23.12.2018 15:01</time>
  </footer>
</article>
<article class="responses__item" data-state="collapsed" data-id="10222009" data-test="responses-item">
  <div>
    <a class="header-h3" data-test="responses-header" href="/services/responses/bank/response/10222009/">
      Не верь рекламе - там обман
    </a>
  </div>

  <div class="responses__item_message" data-preview data-test="responses-message">
    Очень срочно понадобились деньги и решили обратиться в тинькофф банк, т. К по рекламе обещают деньги на следующий день под залог недвижимости.. Чушь полная, уже пошла
```

Значимые элементы кода

```
<article class="responses__item" data-state="collapsed"...>
```

```
<a class="header-h3" data-test="responses-header"  
href="/services/responses/bank/response/10239314/">
```

ЗАГОЛОВОК

```
</a>
```

```
<div class="responses__item__message" data-preview="" data-  
test="responses-message">
```

ТЕКСТ ОТЗЫВА

```
</div>
```

```
<div class="responses__item__message markup-inside-small  
markup-inside-small--bullet" data-full="">
```

ПОЛНЫЙ ТЕКСТ ОТЗЫВА

```
</div>
```

```
</article>
```

Код парсера

```
<?php
require_once 'library/simple_html_dom.php';
$html = new simple_html_dom();
$html = file_get_html('https://www.banki.ru/?rate=1');
foreach($html->find('article.responses__item') as $article) {

    $header = $article->find('a.header-h3', 0)->plaintext;
    $item = $article->find('div.markup-inside-small', 0)->plaintext;

    print("<h3>".$header."</h3>");
    print("<p>".$item);

}
$html->clear();
unset($html);
?>
```

Документация:

[http://simplehtmldom.sourceforge.net/
manual.htm](http://simplehtmldom.sourceforge.net/manual.htm)

Вывод в браузер

Не связывайтесь с Тинькофф - опозоритесь перед своими клиентами

Хочу предупредить всех кто занимается открытием р/с для своих клиентов сотрудничая с Тинькофф: на встречи приезжают безграмотные студенты которые не могут провести грамотное подписание документов по открытию р/с, приходится повторно дергать людей переподписывая документы, не привозят заказанные(!) к р/с корпоративные карты в результате чего люди не могут пользоваться счетом и вносить деньги. В службе поддержки ФИО сотрудников не дают! Т.е. за их безграмотную работу ответственности никто не несет! Не теряйте время, деньги и доверие людей из-за таких банков.

Самовольное подключение платных услуг

Получил СМС "Вам подключена услуга такая-то, 90 дней бесплатно. Чтобы отказаться от подключения, отправьте в течении суток ответное СМС с цифрой 1". Вот и отправляю в ответ цифру 1. Только не по СМС, а сюда. Нагуглил несколько похожих отзывов. Такими рассылками с номера 2273 ТКС баловались и в 2015, и в 2017 году. Представители банка в ответ делают невинные глаза: "удобная же услуга, что вам не нравится?" (потому и не указываю, что за услуга - это неважно). И народ в коментах пишет "отключить можно за 30 секунд - сложно, что ли?". Услуга, может, и удобная. Отключить, может, и несложно. Возмущает-то совсем другое: подключение без спроса. Я не хочу что-то делать для отключения. Я хочу, чтобы меня СНАЧАЛА спросили, надо оно мне или нет. Это низкопробный обман в расчёте на то, что я забуду отправить СМС для отключения. Или просто не стану отвечать, т. к. СМС очень похоже на мошенническое. Все признаки, которые описаны в тинькофф-журнале про мошеннические СМС. Да, так делают почти все - и ОпСоСы, и банки. Но это не оправдание.

Не верь рекламе - там обман

Очень срочно понадобились деньги и решили обратиться в тинькофф банк, т. к. по рекламе обещают деньги на следующий день под залог недвижимости.. Чушь полная, уже пошла вторая неделя после подписания документов, денег так и нет..... Позавчера звонили в банк, сказали ждите представителя, поставьте ещё одну подпись и все деньги сразу придут..... А нет, подпись поставили, представитель уехал, позвонили с банка и сказали ждите ещё в течении двух рабочих дней придут... Сегодня суббота, т. е. во вторник как бы наверно придут и это будет ТРИ НЕДЕЛИ... Зачем вы врете в рекламе и вводите людей в заблуждение...

Честность сотрудников

В декабре 2018 обратился в к/с тинькофф для отключения смс уведомления по карте, специалист убедил меня что можно подключить бесплатную версию на три месяца, я согласился. Проходит месяц смотрю выписку и вижу списание за смс информацию которой даже не получал, позвонил, сказали что это мол за прошлый месяц думаю ладно может быть со следующего, но нет я вновь увидел это списание то есть из этого исходит что специалисты наврали мне два раза. И второе, при оформлении карты мне выдали договор в котором ни слова о штрафе за овердрафт со стороны банка и о чуде при списании комиссии за пользование кредитными деньгами возник овердрафт на сумму около ста рублей и штраф за него 390р. Уважаемый тинькофф банк, я считал вас надёжным банком с известным именем, но такими манипуляциями вы сами себя окунаете в грязь так что вынужден попрощаться с вами.

Тинькофф-Бокс и первое впечатление

Хочу поделиться своими впечатлениями работы с Банком Тинькофф! Обслуживаюсь в банке с начала 2016 года как физ. лицо. С середины февраля 2019 года как ИП, открыл расчетный счет (налетел то, что открыли за 1 час). Повелся на акцию Тинькофф-Бокс. При открытии счета а это 16.02.2019 Бокс не привезли. Недельку жалал пока рассматриваю

2. PHPQuery

Пример: новости

Сейчас в СМИ в Тюмени 2 марта, суббота 04 23

Россия не признает решение гаагского суда по иску «Нафтогаза»

Лукашенко вспомнил о злости на Медведева из-за Абхазии

Появилось видео задержания бойца ММА Александра Емельяненко

В дагестанском селе загорелось два десятка домов

«Не пускать быдло в рестораны»: к экс-жене депутата пришла слава

USD MOEX 65,92 +0,01 EUR MOEX 74,91 -0,09 НЕФТЬ 65,01 -2,05% ...

Загрузите Я.Браузер

Он блокирует шокирующую рекламу 0+

Видео Картинки Новости Карты Маркет Переводчик Музыка Эфир ещё

Яндекс

Найдётся всё. Например, горячая линия мтс

Найти

Скачайте Яндекс.Браузер

polaris

техника для дома и кухни

скидки до 50%

WILDBERRIES

ООО «Вайлдберриз»
МО, д. Мильково, вл. 1,
ОГРН: 1067746062449

Погода

Утром -3,
днём -1

Пробки

1

На дорогах свободно

Карта Тюмени

Такси Расписания

Посещаемое

Авто.ру — угадайте модель BMW

Маркет — люстры и светильники

Недвижимость — с чего начать ремонт

Телепрограмма

Эфир

03:00 Понять. Простить Домашний

03:05 41-летний девственник... ТНТ

03:15 Модный приговор Первый

Сейчас в эфире

Неспиннер МУЗ-ТВ

ЧЗЗ РБК

Чемпионат Голландии. Сезон... Футбол

Значимые элементы кода

```
<div class="content-tabs__items content-tabs__items_active_true"
role="tabpanel" id="tabnews_newsc" aria-labelledby="tabnews_news" aria-
hidden="false">
```

```
<ol class="list news__list">
```

```
<li class="list__item list__item_icon">
```

```
<a
```

```
class="home-link list__item-content home-link_black_yes" aria-
label="Россия не признает решение гаагского суда по иску «Нафтогаза»"
href="https://news.yandex.ru/story/Rossiya_ne_priznaet data-
statlog="news.news.links.1" data-statlog-showed="1">
```

```
<div class="news__agency-icon news__agency-icon-kommersant
news__agency-icon_desktop" title="Коммерсантъ"></div>
```

```
Россия не признает решение гаагского суда по иску
«Нафтогаза»</a></li>
```

```
...
```

```
</ol></div>
```

<https://code.google.com/archive/p/phpquery/downloads>

```
<?php
require ('library/phpQuery.php');
$html = file_get_contents("https://yandex.ru/");
phpQuery::newDocument($html);
```

```
$links = pq("#tabnews_newsc")->find("a");
$tmp = array();
foreach($links as $link){
    $link = pq($link);
    $tmp[] = array(
        "text" => $link->text(),
        "url"  => $link->attr("href")
    );
}
phpQuery::unloadDocuments(); ?>
```

- [Россия не признает решение гаагского суда по иску «Нафтогаза»](#)
- [Лукашенко вспомнил о злости на Медведева из-за Абхазии](#)
- [Появилось видео задержания бойца ММА Александра Емельяненко](#)
- [В дагестанском селе загорелось два десятка домов](#)
- [Представитель Полины Юмашевой подтвердил ее развод с Олегом Дерипаской](#)

```
<ul><?php foreach($tmp as $value): ?>
<li> <a href="<?php echo($value["url"]); ?>" target="_blank">
    <?php echo($value["text"]); ?>
</a>
</li>
<?php endforeach; ?></ul>
```


Результаты парсинга: сохранение

1. Выгрузка в базу данных

2. Сохранение в файл в формате:

CSV

JSON

XML

```
<?php
```

```
$list = array (  
    array('aaa', 'bbb', 'ccc', 'ddd'),  
    array('123', '456', '789'),  
);
```

```
$fp = fopen('file.csv', 'w');  
foreach ($list as $fields) {  
    fputcsv($fp, $fields);  
}
```

```
fclose($fp);
```

```
?>
```

publish_date	headline_text
20030220	в Москве планируется создать нейросеть для считывания показаний счётчиков
20030220	за переводы в Facebook теперь полностью отвечает искусственный интеллект
20030220	нейронные сети Google упростят создание приложений с поддержкой распознавания объектов
20030220	носимое устройство на базе ИИ отличает человека от машины по голосу
20030220	google внедрила искусственный интеллект в свои облачные сервисы
20030220	найлены области мозга которые распознают летящий в лицо предмет
20030220	для распознавания лиц импульсная нейронная сеть лучше чем свёрточная
20030220	медики обнаружили новое полезное свойство чтения
20030220	знаменитый ученый стивен хокинг рассказал в интервью о будущем человечества на марсе
20030220	колонизация марса произойдет в течение ближайших ста лет
20030220	стивен хокинг уверен что марс будет колонизирован людьми в ближайшее столетие
20030220	марс наиболее похожая на землю планета солнечной системы
20030220	полет человека на марс с помощью пилотируемого космического корабля
20030220	уже в ближайшее столетие люди заселят марс
20030220	стивен хокинг назвал микроскопические черные дыры источником неограниченной энергии
20030220	популярный британский ученый рассказал что будет с человечеством
20030221	стивен хокинг высказался против выхода великобритании из ес
20030221	роскосмос продолжит работу над рядом ключевых проектов лунной программы
20030221	специалисты разработали специального робота-строителя
20030221	учёные сша сделали первый шаг на пути к колонизации марса и луны
20030221	американцы создали робота-строителя для колонизации марса и луны.
20030221	астроном владимир сурдин усомнился в возможной колонизации марса в ближайшие годы
20030221	первый опыт колонизации марса закончился условной гибелью людей
20030221	в Москве планируется создать нейросеть для считывания показаний счётчиков
20030221	за переводы в Facebook теперь полностью отвечает искусственный интеллект
20030221	нейронные сети Google упростят создание приложений с поддержкой распознавания объектов
20030221	носимое устройство на базе ИИ отличает человека от машины по голосу
20030221	google внедрила искусственный интеллект в свои облачные сервисы
20030221	найлены области мозга которые распознают летящий в лицо предмет
20030221	для распознавания лиц импульсная нейронная сеть лучше чем свёрточная
20030221	медики обнаружили новое полезное свойство чтения
20030221	знаменитый ученый стивен хокинг рассказал в интервью о будущем человечества на марсе